


학생의 시스템은 PC에서, 모델 요청은 LiteLLM을 통해

코딩 에이전트는 학생 PC에서 파일 수정·명령 실행을 돕고, LiteLLM은 모델 요청과 학생별 접근·사용량을 중계·관리합니다.



응답은 반대 방향으로 돌아옵니다. Cloud Run에 올리려는 것은 중계 프로그램이며, 모델 추론용 GPU 서버가 아닙니다.

학생 PC에 두는 것

교육용 플랫폼·관제, 분석·시뮬레이터, PostgreSQL·Neo4j, 개인 코드와 산출물. MCP로 연결하는 로컬 도구도 이 실행 환경에 속합니다.

중앙에 두는 것

LiteLLM, 가상키·사용량을 보관할 운영 DB, 제공사 키 보관, 모델 접근 설정과 모니터링. 중앙 DB는 학생의 설비 관측 DB와 별개입니다.

요청 한 번의 경로

① 학생이 코딩 에이전트에 요구합니다. ② 에이전트가 필요한 프롬프트·코드 문맥을 중계 주소로 보냅니다. ③ LiteLLM이 키와 허용 설정을 확인해 제공사로 전달합니다. ④ 응답을 받은 코딩 에이전트가 로컬 도구를 실행하고 학생이 결과를 확인합니다.


로컬 실행이어도 모델에 전달하는 프롬프트·선택된 코드·도구 결과는 외부 요청에 포함될 수 있습니다. “데이터가 전혀 PC 밖으로 나가지 않는다”는 구조가 아닙니다. 전달 범위와 로그 보관 정책을 정해야 합니다.

합의한 방향 학생별 로컬 + 중앙 LiteLLM, 코딩 기본 모델 GPT-5.6 Luna. **검증 필요** 실제 API 모델 ID·코딩 도구 호환·비용. 플랫폼 내부 업무 에이전트의 중계 연결도 코딩 도구와 별도로 시험해야 합니다.

기술 근거: [LiteLLM Virtual Keys](#) — 가상키·모델 접근·사용량 관리와 PostgreSQL 요구사항.

공유 주소를 만들기 전에 확인할 것

배포 후보 Cloud Run에서 LiteLLM을 실행하는 기존 운영 제안을 설명합니다. 현재 중앙 중계의 배포·동시 사용·비용 검증 완료 증거는 없습니다.



준비 단계	협업자가 확인할 결과
1. 운영 범위 결정	GCP 프로젝트·리전·운영 담당자·결제 주체·DB 방식·접근 정책. 학생용 중계와 관리자 기능의 접근 범위를 구분.
2. 배포 설정 준비	고정한 이미지 버전, 모델 매핑, DB 연결, 비밀번호 참조, 요청 제한시간·동시성·인스턴스 설정. 예전 가정값을 확정 사양으로 복사하지 않음.
3. 학생 키 연결	학생별 가상키, 중계 주소, 허용 모델. 원본 제공사 키와 관리용 마스터키는 학생에게 배포하지 않음.
4. 실제 사용 확인	일반 응답·스트리밍·도구 호출·긴 요청, 만료키·한도 도달·429·중계 장애 처리. 재시작 뒤 키와 기록 보존, 여러 인스턴스의 제한·집계 일관성.
5. 파일럿과 운영	학생 ID·회차·요청 ID·모델·입출력 토큰·지연·실패·비용을 대조. 사용자 실습 완주·비용 실측 후 사양과 예산 조정.

비용 항목: 모델 API + 중계 실행 + 운영 DB + 비밀·로그·네트워크 등. LiteLLM 사용량과 제공사 청구를 대조합니다. 설정한 예산이 정확한 최종 청구 상한으로 작동하는지도 시험해야 합니다.

현재 확인: 로컬 플랫폼 기동과 일부 기능 검사·관제 첫 화면 캡처. **남은 확인:** 중앙 중계, 모델 호환, 동시 사용, 학생 완주, 비용. 이 문서는 배포 명령 실행 결과나 학생 설치 가이드가 아닙니다.

기술 근거: [Cloud Run 비밀번호 연결](#) · [요청 제한시간](#) · [LiteLLM 가상키](#).
프로젝트 근거: 학교회차 대응표, compose.local.yml, 첫날~다섯째날 기능 기록, 현재 운영 합의. 과거 리뉴얼의 시나리오·가격표는 현재 구현 근거로 사용하지 않음.